

Revisão Rápida da Literatura sobre Padrões suspeitos de Fraudes em Transações Pix

Este capítulo apresenta a condução e os resultados de um mapeamento sistemático de literatura, cujo objetivo consistiu em identificar e caracterizar as ameaças de privacidade mais críticas em fraudes e as soluções para mitigá-las e tratá-las.

3.1 Introdução

Para propor soluções eficazes no combate à fraude em transações financeiras, especialmente no contexto de pagamentos instantâneos como o Pix, é fundamental compreender o panorama atual das pesquisas existentes. Isso permite não apenas conhecer as abordagens e técnicas já aplicadas, mas também identificar limitações, desafios e lacunas ainda presentes na literatura. A partir desse diagnóstico, torna-se possível desenvolver soluções mais robustas e alinhadas às demandas do cenário atual.

Com esse objetivo, optou-se pela realização de uma Revisão Rápida da Literatura (RRL), uma metodologia de síntese de evidências que busca fornecer uma visão abrangente e estruturada sobre determinado tema, utilizando procedimentos sistemáticos, porém com prazos e escopos reduzidos em comparação às revisões sistemáticas tradicionais (Tricco et al., 2017). Esse tipo de revisão tem sido amplamente adotado, sobretudo em áreas que demandam respostas ágeis para problemas emergentes, como é o caso da segurança em transações financeiras digitais.

Diferente de revisões narrativas, que podem ser mais suscetíveis a vieses subjetivos, as revisões rápidas seguem um protocolo pré-definido, que inclui a definição clara dos objetivos, das questões de pesquisa, das estratégias de busca, dos critérios de inclusão e exclusão, e do processo de extração e síntese dos dados (Hamel et al., 2021; Garritty et al., 2021). Dessa forma, assegura-se maior rigor metodológico, mantendo, ao mesmo tempo, uma execução mais ágil e focada.

Este capítulo tem como objetivo descrever o protocolo adotado para conduzir a Revisão Rápida da Literatura, detalhando cada uma de suas etapas. Através dessa revisão, busca-se mapear e analisar os principais estudos relacionados à detecção de fraudes em transações financeiras utilizando técnicas de aprendizado de máquina, com especial atenção às adaptações necessárias para o contexto do Pix. A partir dos resultados obtidos, espera-se não apenas fundamentar teoricamente o desenvolvimento deste trabalho, mas também contribuir para o avanço do conhecimento na área de segurança em meios de pagamento digital.

3.2 Protocolo da Revisão Rápida da Literatura

O protocolo de uma Revisão Rápida da Literatura (RRL) define, de maneira estruturada, os procedimentos, critérios e instrumentos que serão empregados durante

todo o processo de revisão. A adoção de um protocolo bem delineado tem como objetivo principal garantir a transparência, a reprodutibilidade e a redução de vieses por parte dos pesquisadores, assegurando que os resultados obtidos sejam confiáveis e metodologicamente robustos (Hamel et al., 2021).

3.2.1 Objetivo

O objetivo desta RRL está estruturado de acordo com o paradigma GQM (*Goal Question-Metric*) proposto por Basili and Rmbach (1988) e está definido na Tabela 3.2.1.

Tabela 3.2.1: Objetivo do MSL segundo paradigma GQM

Analisar as	Publicações científicas
Com o propósito de	Identificar fraudes através de algoritmos
Com relação a	Padrões suspeitos em transações financeiras
Do ponto de vista dos	Pesquisadores
no contexto de	Segurança digital e prevenção de fraudes bancárias

3.2.2 Questões de Pesquisa

De acordo com o objetivo proposto, as questões de pesquisas definidas para este MSL são apresentadas a seguir:

QP-1. Quais características das transações financeiras podem ser utilizadas para identificar padrões suspeitos de fraude no Pix?

QP-2. Qual a eficácia do uso de algoritmos de Machine Learning na detecção de fraudes em transações Pix em um ambiente de Big Data?

A QP-1 visa identificar os principais fatores que podem indicar padrões suspeitos de fraude em transações Pix. Isso inclui características como o valor da transação, a frequência das operações, o horário em que ocorrem, a localização do remetente e do destinatário, além do histórico de comportamento do usuário. A QP-2 busca avaliar a eficiência dos algoritmos de Machine Learning na identificação de fraudes em transações Pix quando aplicados em um ambiente de Big Data com Spark. Para isso, são analisadas métricas como precisão, *recall* e *F1-score*, além de estratégias para lidar com o desbalanceamento de classes.

3.2.3 Estratégia de busca dos artigos

Em qualquer Revisão Rápida da Literatura (RRL), é fundamental que o pesquisador adote uma estratégia de busca bem definida, associada a critérios rigorosos de seleção. Isso garante que sejam incluídas apenas publicações que sejam relevantes e alinhadas aos objetivos e às questões de pesquisa previamente estabelecidas. Dessa

forma, minimiza-se a inclusão de estudos irrelevantes e reduz-se a possibilidade de viés na seleção (Moher et al., 2015).

A estratégia de busca adotada nesta RRL foi composta por dois elementos principais: (i) a definição das bases de dados e (ii) o tipo de publicação a ser considerado. Com relação às bases de dados, optou-se por utilizar as bibliotecas digitais Scopus, Wiley e ACM Digital Library, selecionadas pela ampla cobertura de pesquisas nas áreas de ciência de dados, segurança da informação e aprendizado de máquina. Além disso, essas bases são reconhecidas internacionalmente pela qualidade das publicações, todas submetidas ao processo de revisão por pares.

Foi realizado um teste preliminar na base google acadêmico, porém identificou-se que uma parcela significativa de artigos eram voltadas para cartão de crédito os resultados foram baixos em relação a artigos sobre detecção de fraudes em pix e sobre questões de duplicados em relação às bases Scopus, Wiley e ACM Digital Library tivemos apenas 3, além de não agregar novos estudos altamente relevantes para os critérios definidos. Por esse motivo, a busca foi concentrada nas três bases citadas.

Quanto ao tipo de documento, foram considerados exclusivamente artigos científicos publicados em periódicos, congressos e conferências revisados por pares, devido à credibilidade e à qualidade metodológica que esse tipo de publicação oferece. Documentos como resumos simples, editoriais, dissertações, teses e pré-prints foram excluídos, de modo a garantir maior rigor na seleção dos dados.

A construção da *string* de busca foi realizada com base na metodologia PICOC (Population, Intervention, Comparison, Outcome), conforme recomendado por Methley et al. (2014). No entanto, os parâmetros *Comparison* e *Outcome* não foram aplicados, uma vez que o objetivo da revisão não é comparar abordagens, mas sim mapear as soluções existentes para detecção de fraudes em transações financeiras. Assim, os elementos *População*, *Intervenção* e *Resultados* foram priorizados, estruturando termos relacionados a “fraude financeira”, “pagamentos digitais”, “deep learning”, “machine learning” e “inteligência artificial”.

A *string* final foi adaptada para a sintaxe de cada base e validada por meio de testes-piloto para garantir que estivesse recuperando estudos pertinentes ao escopo definido conforme apresentado na tabela .

Tabela 3.2.3: *Strings* de busca utilizadas no RRL

Critério PICOC	<i>Strings</i> de busca
População	"machine learning" OR "deep learning" OR "artificial intelligence"
Intervenção	"Pix transaction" OR "Pix payment" OR "instant payment" OR "digital payment" OR "electronic transaction" OR "Brazilian payment system"
Resultado	"fraud detection" OR "fraudulent transaction" OR "fraud detection system" OR "fraud classification"

3.2.4 Critérios para seleção dos artigos

Os critérios de seleção definem se um artigo será ou não excluído da RRL, visando garantir sempre a relevância dos artigos para o contexto desta pesquisa. A tabela 3.2.4 apresenta os critérios de seleção definidos neste RRL.

Tabela 3.2.4: Critérios de seleção do artigos

Critérios	Critérios de inclusão
CI-1	O artigo descreve técnicas de Machine Learning aplicadas à detecção de fraudes financeiras.
CI-2	O artigo apresenta análise de padrões suspeitos em transações, incluindo Pix.
CI-3	O artigo propõe ou avalia modelos de aprendizado de máquina para identificação de fraudes em transações financeiras.
CI-4	O artigo compara diferentes algoritmos de Machine Learning na detecção de fraudes.
CI-5	O artigo descreve estudos experimentais que avaliam a eficácia de diferentes algoritmos na detecção de fraudes financeiras.
Critérios	Critérios de exclusão
CE-1	O artigo não atende nenhum dos critérios de inclusão acima.
CE-2	O artigo completo não está disponível para download ou nas fontes de busca.
CE-3	O artigo não é uma publicação científica revisada por pares (blog, capítulo de livro, relatório técnico sem <i>peer review</i>).
CE-4	O artigo está em um idioma que não seja português ou inglês.
CE-5	O artigo é duplicado ou já foi selecionado em outra busca.

3.3 Execução do Mapeamento Sistemático

Para a execução de busca de artigos nas bases, a pesquisadora responsável pelo RRL aplicou as Strings de buscas nas bases de dados selecionados e armazenou o conjunto de referências recuperadas na ferramenta Parsifal para análise posterior. E garantir que a confiabilidade dos resultados obtidos estejam corretos. Para estruturar o processo de execução do RRL, foi definido um procedimento com duas etapas:

- **Processo de seleção preliminar (1º filtro):** Nesta etapa, a pesquisadora avaliou o título, resumo e palavras-chave do conjunto de artigos retornado nos mecanismos de busca, de acordo com os critérios de inclusão e exclusão estabelecidos.

- **Eliminação por leitura total (2º filtro):** Esta etapa consistiu em uma leitura total dos artigos (introdução, fundamentação, metodologia e conclusão), dos artigos selecionados, para analisar se o mesmo estava associado às questões de pesquisa. Nesta etapa também foram aplicados os critérios de inclusão e exclusão estabelecidos.

3.3.1 Artigos selecionados no RRL

Inicialmente, o RRL foi executado em 2025. Toda a seleção se deu pela busca de artigos entre 2020 até o presente ano de 2025. Conforme ilustrado no Capítulo 3. Uma Revisão Rápida da Literatura sobre Detecção de Fraudes Financeiras no Sistema de Transferência Pix usando Algoritmos de Aprendizagem de Máquina na Figura 3.3.1, foram retornados 114 publicações como resultado da busca inicial nas bibliotecas selecionadas (primeiro filtro). Desse total, 44 artigos foram obtidos na biblioteca digital *Scopus*, 55 na *ACM* e os outros 15 na *Wiley*. Após a remoção dos duplicados, o número de publicações selecionadas para a leitura dos títulos, resumos e palavras-chaves (primeiro filtro) foi de 111 artigos. Após a aplicação dos critérios de inclusão e exclusão nessas publicações 53 foram selecionados pára a aplicação do segundo filtro. Todas as 53 publicações foram lidas por meio da leitura total (introdução, fundamentação, metodologia e conclusão), e apenas 53 publicações atenderam aos critérios de inclusão. Por fim, após a leitura completa desses artigos (segundo filtro), um total de 29 artigos foram selecionados para extração de dados.

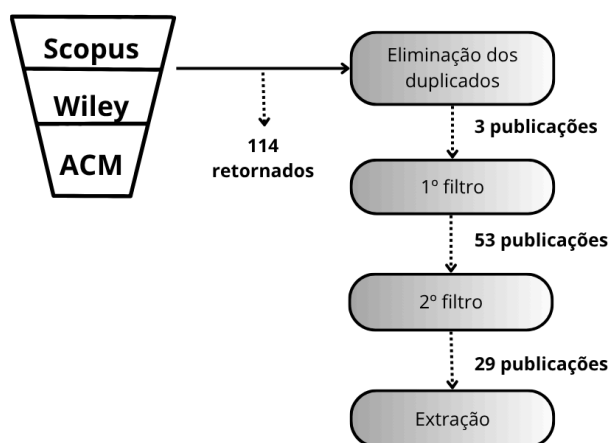


Figura 3.3.1: Resultado do processo de seleção dos artigos

Fonte: Próprio Autor.

A tabela 3.4 lista o conjunto de artigos selecionados na revisão rápida. Os artigos estão caracterizados através dos códigos (A1, A2...), que busca representar a ordem de numeração dos mesmos. No final de cada artigo é apresentada a máquina de busca a qual o mesmo foi identificado.

Tabela 3.4: Artigos selecionados na Revisão Rápida

Código	Título dos Artigos	Referências
A1	A DQN-based Internet Financial Fraud Transaction Detection Method [ACM]	(Wang et al., 2021)
A2	AI versus AI in Financial Crimes & Detection: GenAI Crime Waves to Co-Evolutionary AI [ACM]	(Kurshan et al., 2024)
A3	A hybrid method with dynamic weighted entropy for handling the problem of class imbalance with overlap in credit card fraud detection [SCOPUS]	(Li et al., 2021)
A4	A Machine Learning Method with Hybrid Feature Selection for Improved Credit Card Fraud Detection [SCOPUS]	(Mienye et al., 2023)
A5	A Multi-perspective Fraud Detection Method for Multi-Participant commerce Transactions [SCOPUS]	(Yu et al., 2024)
A6	A Credit Card Fraud Detection Algorithm Based on SDT and Federated Learning [SCOPUS]	(Tang et al., 2024)
A7	A rule based approach to minimize false-positive declines in Electronic Card Not Present financial transactions using feature engineering techniques [SCOPUS]	(Delgolla et al., 2021)
A8	An Ensemble Machine Learning Model For Classification Of Credit Card Fraudulent Transactions [SCOPUS]	(Mathew and Tina Elizabeth, 2023)
A9	Automatic Machine Learning Algorithms For Fraud Detection In Digital Payment Systems [SCOPUS]	(Kolodiziev et al., 2020)
A10	Digital Payment Fraud Detection Methods in digital ages and Industry 4.0 [SCOPUS]	(Chang et al., 2022)

continua na próxima página

Tabela 3.4 - continuação da página anterior

A11	Credit Card Fraud Detection Using Machine Learning Techniques [SCOPUS]	(Tang et al., 2023)
A12	Hybrid machine learning system for solving fraud detection tasks [SCOPUS]	(Vynokurova et al., 2020)
A13	Enhancing Trust and Safety in Digital Payments: An LLM-Powered Approach [SCOPUS]	(Dahiphale et al., 2024)
A14	Evaluating the Computational Advantages of the Variational Quantum Circuit Model in Financial Fraud Detection [SCOPUS]	(Tudisco et al., 2024)
A15	Financial Crime Fraud Detection Using Graph Computing: Application Considerations Outlook [SCOPUS]	(Kurshan et al., 2020)
A16	Graph Computing for Financial Crime and Fraud Detection: Trends, Challenges and Outlook [SCOPUS]	(Liu et al., 2020)
A17	Impact of Deep Feature Synthesis on Deep Learning in Electronic Transaction Fraud Detection [SCOPUS]	(Uddin et al., 2023)
A18	Leveraging ensemble learning for enhanced security in credit card transaction fraudulent within smart cities for cybersecurity challenges [SCOPUS]	(Padhi et al., 2024)
A19	Optimizing fraud detection in financial transactions with machine learning and imbalance mitigation [SCOPUS]	(Al-dahasi et al., 2025)
A20	Advancements in Credit Card Fraud Detection: A Comprehensive Evaluation of Current Approaches [SCOPUS]	(Panthakkan et al., 2024)
A21	Cost-Sensitive Model Evaluation Approach for Financial Fraud Detection System [SCOPUS]	(Pant et al., 2021)

Tabela 3.4 - continuação da página anterior

A22	Detection of Fraudulent Activities in Unified Payments Interface using Machine Learning - LSTM Networks [SCOPUS]	(Raju et al., 2024)
-----	--	---------------------

A23	Ensemble Approach for Credit Card Fraud Detection Using Champion-Challenger Analysis [SCOPUS]	(Muhall et al., 2022)
A24	Fraud Detection on Bank Payments Using Machine Learning [SCOPUS]	(Ranjan et al., 2022)
A25	Monitoring and detection of NEFT fraudulent requests: A comparative analysis of machine learning models [SCOPUS]	(Bhowmik et al., 2024)
A26	Optimizing Logistic Regression for Flawless Fraud Detection in Digital Payments [SCOPUS]	(Kant and Vishnu, 2024)
A27	Big Data, AI and Machine Learning [WILEY]	(Dubovi and Omri, 2020)
A28	Financial Fraud Detection Approach Based on Firefly Optimization Algorithm and Support Vector Machine [WILEY]	(Singh et al., 2022)
A29	Artificial Intelligence Applications in the Indian Financial Ecosystem [WILEY]	(Manda et al., 2024)

Referências

- Tricco, A. C., et al. (2017). *PRISMA Extension for Scoping Reviews (PRISMA-ScR): Checklist and Explanation*. Annals of Internal Medicine.
- Hamel, C., et al. (2021). *What is a rapid review? A methodological exploration of rapid reviews in health research*. Systematic Reviews.
- Hamel, C., Michaud, A., Thuku, M., Skidmore, B., Stevens, A., Nussbaumer-Streit, B., et al. (2021). *Defining rapid reviews: a systematic scoping review and thematic analysis of definitions and processes*. Systematic Reviews.
- Garrity, C., et al. (2021). *Cochrane Rapid Reviews Interim Guidance*. Cochrane.
- Moher, D., et al. (2015). *Preferred reporting items for systematic reviews and meta-analyses: the PRISMA statement*. Systematic Reviews.
- Methley, A. M., Campbell, S., Chew-Graham, C., McNally, R., & Cheraghi-Sohi, S. (2014). *PICO, PICOS and SPIDER: a comparison study of specificity and sensitivity in three search tools for qualitative systematic reviews*. BMC Health Services Research.

